Использование LLM

Короткий ответ: **платформа полностью работает без LLM и без ключей** (так работает демо-стенд жюри). Языковая модель — необязательная надстройка в двух местах разбора текста и один офлайн-инструмент авторов банка заданий. В тесте, оценке, ранжировании и объяснениях её нет и быть не может.

Организаторы разрешили облачные LLM (в том числе зарубежные; предпочтительны открытые модели) при условии, что команда документирует, какие модели, как и зачем используются, и берёт на себя риски 152-ФЗ, если ПДн уходят в модель. GPU на стенде жюри нет, поэтому локального инференса в поставке нет: модель — всегда внешний API.

1. Где LLM используется

#	Место	Что делает модель	Режим по умолчанию	Если модели нет
1	Разбор брифа работодателя (`app/services/matching/llm_brief.py` , задача `brief_skills`)	Только **добавляет** навыки, которые пропустили правила разбора; вид навыка всегда «желательный»	Выключено	Бриф разбирают правила; результат тот же, что в демо
2	Разбор резюме кандидата (`app/services/resume/parser.py` , задача `resume`)	Только **добавляет** навыки, роли, soft skills, заявленный грейд, которых не нашли правила	Выключено	Работают правила
3	Офлайн, у авторов банка: черновики генераторов семейств заданий	«LLM пишет генератор, а не задание» (см. §4)	Не часть продукта	—

Общие гарантии для пунктов 1 и 2 (шлюз `app/llm/gateway.py`):

- **Только добавление и только с цитатой.** Каждое поле от модели обязано прийти с дословной цитатой из текста (`rapidfuzz.partial_ratio ≥ 90` , `VZ_LLM_MIN_QUOTE_RATIO`). Поле без цитаты, с чужим названием или вне справочника навыков отбрасывается. Результат правил модель изменить не может.
- **Чипы помечены источником**: «правило», «вручную» или имя провайдера; для резюме все элементы — серые «заявлено», подтверждением не считаются.
- **Детерминированный fallback.** Цепочка провайдеров → «без LLM»: сбой, таймаут (общий бюджет 20 с на разбор), невалидный JSON или промах кассеты дают тот же результат, что и выключенная модель. Исключения провайдера в разбор не пробрасываются.
- **Воспроизводимость.** Кэш по `sha256(версия промпта + задача + замаскированный текст)` . Режимы `VZ_LLM_MODE` : `record` (провайдеры плюс запись ответов в JSON-кассету), `replay` (только кассета, без сети и ключей — демо с LLM воспроизводимо). В кассете нет текста запроса, только ключ `sha256` и ответ модели на замаскированный текст.
- **Температура 0** у всех провайдеров (у GigaChat 0,01: строгий 0 он не принимает).

2. Где LLM запрещена и почему

Запрещена в: выдаче и ключах заданий, сложности `b` , адаптивном выборе и остановке теста, определении грейда и категории, Score, ранжировании подборки, объяснениях «почему выше», вердиктах «Антиподсказчика», раскрытии контактов.

Причины:

1. **Сопоставимость.** Результат теста должен быть сравним между людьми и между попытками. Задание «под каждого» от модели не имеет известной сложности, а ключи модели ошибаются: в симуляции каждые 5 % битых ключей заметно снижают долю верных решений (VALIDATION.md §2.5; долю ошибок у реальных моделей мы не измеряли). Ключи считает исполнение кода генератора, не модель.

2. **Воспроизводимость и аудит.** Подборка и объяснения обязаны быть повторяемыми и проверяемыми (в Score «сумма вкладов = итог» проверяется тестом); недетерминированная модель в этой цепочке разрушает проверяемость.
3. **152-ФЗ, ст. 16.** Решение о человеке не принимается автоматически без человека; модель не должна влиять на то, кого показывают работодателю.
4. **Резюме не влияет ни на категорию, ни на Score** (правило продукта): даже то, что модель извлекла из резюме, остаётся серым «заявлено».

Как это защищено в коде и тестах:

- Модули Score, ранжирования, объяснений не импортируют `app.llm`: `tests/test_api_needs_review.py::test_ranking_path_never_imports_llm`; в `app/testing` и `app/services/testing` импортов `app.llm` нет.
- **Поведенческий тест** `tests/test_llm_boundaries.py`: шлюз подменён на «включённый» с записью каждого обращения (и провайдеры тоже перехвачены). Полная сессия адаптивного теста с результатом, сборка версии подборки, выдача, карточка кандидата — **0 обращений**. Единственное допустимое обращение на стороне работодателя — `brief_skills` при разборе брифа.

3. Какие модели

Шлюз поддерживает три вида провайдеров; цепочка при `VZ_LLM_PROVIDER=auto` идёт в порядке ниже, неподключённые пропускаются.

Провайдер	Значение `VZ_LLM_PROVIDER`	Модель по умолчанию	Для чего	Юрисдикция
YandexGPT (Foundation Models API)	`yandexgpt`	`yandexgpt-lite/latest`	Основной для боевой установки: данные остаются в РФ	РФ
GigaChat	`gigachat`	`GigaChat` (scope `GIGACHAT_API_PERS`)	Резерв в РФ; TLS проверяется по сертификату НУЦ Минцифры (`VZ_LLM_GIGACHAT_VERIFY`)	РФ
OpenAI-совместимый API	`openai_compat`	`qwen/qwen3-235b-a22b-2507` (меняется `VZ_LLM_OPENAI_MODEL`)	**Открытые модели** (Qwen, Llama, DeepSeek, gpt-oss) у облачных хостингов — OpenRouter, Together, Fireworks и им подобных; собственный vLLM/Ollama, если появится GPU; при необходимости зарубежные API	Зависит от хостинга

Зачем именно эти: задача модели узкая (извлечь названия технологий с цитатой из короткого текста), поэтому нужна не мощная, а дешёвая и быстрая модель с хорошим русским; точность держит проверка цитаты, а не размер модели. Открытая модель через OpenAI-совместимый адрес даёт предпочтительный организаторами вариант без GPU на нашей стороне и без привязки к вендору.

4. Офлайн-использование: «LLM пишет генератор, а не задание»

Авторы банка заданий могут использовать LLM как помощника при написании **кода семейства** (шаблон текста, генератор параметров, эталонный решатель). Это инструмент разработки, не часть продукта и не вызывается рантаймом. Правила:

- Ключи ответов считает **исполнение** решателя, а не модель; черновик проходит автоматические гейты банка (`app/testing/bank/base.py`, тесты `tests/test_bank_*`: идемпотентность клонов, проверка ключей исполнением, отсутствие утечек) и ревью человека.
- Затем pretest с весом 0 и калибровка по ответам людей; без измеренной сложности семейство в оценку не входит.

- Автоматического конвейера «фабрика семейств» в репозитории **нет** (в TESTING_MECHANISM.md §13 он числится в плане): черновики генераторов писались с помощью ассистента и прошли ту же проверку исполнением и ревью. Никаких ПДн в этом процессе нет.

5. Политика ПДн

Что **не уходит** в модель никогда: контакты и ПДн кандидата из профиля, результаты тестов, ответы на задания, Score, данные ФСП, содержимое подборок и приглашений. Эти данные в шлюз не передаются: он вызывается только с текстом брифа (задача `brief_skills`) и текстом резюме (задача `resume`).

Что уходит и как защищено:

Текст	Что в нём	Меры
Бриф работодателя	Описание вакансии: стек, вилка, формат. ПДн кандидатов нет; возможны имена контактных лиц компании	Маскирование тем же модулем; только задача `brief_skills`
Резюме кандидата	Может содержать ПДн	**Маскирование до вызова** (`app/llm/masking.py`): email, телефоны, ссылки на профили и Telegram, строки с датой рождения/возрастом, ФИО, найденные правилами, заменяются на `*` с сохранением длины (смещения цитат совпадают с исходным текстом); `extra_pii_spans` добавляет найденные ФИО. Текст обрезается до `VZ_LLM_MAX_INPUT_CHARS` (12 000)

Остаточный риск, который берёт на себя команда: маскирование основано на правилах, поэтому ФИО, не распознанные правилами, и косвенные идентификаторы (названия мест работы, должности с датами) в замаскированном тексте могут остаться. Поэтому:

1. **По умолчанию LLM выключена**; в демо-стенде и у жюри текст резюме и брифа никуда не уходит.
2. **Российские провайдеры (YandexGPT, GigaChat) — для боевой установки с резюме**: данные не покидают РФ (ст. 18 ч. 5 152-ФЗ).
3. **Зарубежный/внешний OpenAI-совместимый адрес по умолчанию получает только задачу `brief_skills`** (`VZ_LLM_OPENAI_TASKS=brief_skills`). Задача `resume` уйдёт туда только если оператор явно добавит её в `VZ_LLM_OPENAI_TASKS`; тогда он обязан оценить трансграничную передачу (ст. 12) и получить согласие кандидата. Это защищено тестом (`test_openai_compat_provider_and_task_restriction`).
4. **Известное ограничение:** отдельной цели «обработка резюме языковой моделью» в журнале согласий (`ConsentPurpose`) пока нет. Поэтому для боевой установки с включённым разбором резюме моделью её нужно добавить (отдельная галочка с версией текста) или ограничиться уведомлением в согласии на обработку; в демо и у жюри функция выключена. Секреты ключей — `SecretStr`, в логи не пишутся.

6. Как включить

Всё через окружение (`.env.example`, раздел «LLM»). Без ключей и без изменений ничего не вызывается.

```
# Российский провайдер (боевая установка)
VZ_LLM_PROVIDER=yandexgpt
VZ_LLM_YANDEX_API_KEY=...        # ключ сервисного аккаунта
VZ_LLM_YANDEX_FOLDER_ID=...

# Открытая модель через OpenAI-совместимый хостинг (брифы; резюме не уходит)
VZ_LLM_PROVIDER=openai_compat
VZ_LLM_OPENAI_BASE_URL=https://openrouter.ai/api/v1
VZ_LLM_OPENAI_API_KEY=...
VZ_LLM_OPENAI_MODEL=qwen/qwen3-235b-a22b-2507

# Цепочка: YandexGPT -> GigaChat -> OpenAI-совместимый -> без LLM
```

```
VZ_LLM_PROVIDER=auto

# Демо с «включённой» LLM без сети и ключей (кассета записывается один раз через VZ_LLM_MODE=record)
VZ_LLM_MODE=replay
VZ_LLM_CASSETTE_PATH=/app/data/llm-cassette.json
```

Признак для проверяющего: в ответе разбора брифа `llm_used` и поле `source` чипов («YandexGPT» / «GigaChat» / `openai_compat`); при выключенной модели `llm_used=false`, все чипы «правило» или «вручную».

7. Стоимость и ресурсы

Нагрузка на модель мала: один вызов на разбор брифа или резюме, кэш по `sha256` убирает повторы, правила отрабатывают первыми. Порядок величин для оценки бюджета (тарифы провайдеров меняются, актуальные проверять перед включением):

Операция	Токены (вход / выход)	Комментарий
Бриф	≈ 0,5–1 тыс. / ≈ 0,2 тыс.	Один вызов на версию текста
Резюме	≈ 1–3 тыс. / ≈ 0,3 тыс.	Один вызов на загрузку, вход ограничен 12 000 символов

Для десятков разборов в день, как у демо и пилота, это единицы рублей в сутки у российских провайдеров и копейки у открытых моделей на хостингах. Лимиты запросов к API кандидата и работодателя ограничивают число вызовов сверху. GPU, собственного инференса и дополнительных сервисов не требуется; без ключей затрат нет.

8. Как проверить

```
cd backend
uv run pytest -q tests/test_llm_boundaries.py tests/test_resume_llm.py
tests/test_api_needs_review.py::test_ranking_path_never_imports_llm
```

Тесты проверяют: умолчание «выключено» (ни провайдеров, ни обращений), 0 обращений в сессии теста и ранжировании, ограничение задач зарубежного провайдера и маскирование ПДн в запросе, деградацию в «без LLM» при ошибке провайдера, цитатную проверку и кассету.